Module05-03 C++ Boost: 正则表达式

C++ Boost - 正则表达式

轩辕打墙训

- 容器相关
- 字符串和文字处理
- → 正则表达式
- 智能指针
- 函数对象相关
- 序列化
- 日期与时间
- 多线程
- 网络

■ 正则表达式:

- 语法
- 类 regex
- 类 match results
- 类 sub_match
- 算法 regex_match()、 regex_search()、 regex_replace()
- 迭代器 regex_iterator 、 regex_token_iterator
- 示例

正则表达式 - 语法



- 正则表达式语法
 - ◆ boost.regex 的语法默认基于 Perl 语言的正则表达式语法
 - 语法包括匹配(搜索)和替代两个部分
 - 具体语法描述见 Boost Regex Doc Perl Regular Expression Syntax 一节
 - ▶ (参考语法测试示例: regex_syntax.txt)

正则表达式 - 类 regex



■ 正则表达式:

- 语法
- 类 regex
- 类 match results
- 类 sub_match
- 算法 regex_match()、 regex_search()、 regex_replace()
- 迭代器 regex_iterator 、 regex_token_iterator
- 示例

正则表达式 - 类 regex



- 关于 class regex
 - class regex 用一系列的字符构建一个合法的正则表达式,本质上讲就是一个 string(字符串对象)
 - 如果给定的字符序列无法构建一个合法的正则表达式,将抛出 一个异常,以示构造失败

■ 构造、复制

```
template<class charT, class traits = regex traits<charT> >
class basic regex {
public:
    // construct/copy/destroy:
    explicit basic regex();
    explicit basic regex(const charT* p,
            flag type f = regex constants::normal);
   basic regex(const charT* p1, const charT* p2,
            flag type f = regex constants::normal);
    basic regex(const charT* p, size type len, flag type f);
    basic regex(const basic regex&);
    template<class ST, class SA>
    explicit basic regex(const basic string<charT, ST, SA>& p,
            flag type f = regex constants::normal);
    template<class InputIterator>
    basic regex(InputIterator first, InputIterator last,
            flag type f = regex constants::normal);
    ~basic regex();
```

赋值

```
basic regex& operator=(const basic regex&);
    basic regex& operator=(const charT* ptr);
    template<class ST, class SA>
    basic regex& operator=(const basic string<charT, ST, SA>&
p);
    basic regex& assign(const basic regex& that);
    basic regex& assign(const charT* ptr,
            flag type f = regex constants::normal);
    basic regex& assign(const charT* ptr,
            unsigned int len, flag type f);
    template < class string traits, class A>
    basic regex& assign(
        const basic string<charT, string traits, A>& s,
        flag type f = regex constants::normal);
    template<class InputIterator>
    basic regex& assign(InputIterator first,
        InputIterator last,
        flag type f = regex constants::normal);
```



■ 常用操作

```
// iterators:
std::pair<const iterator, const iterator>
subexpression(size type n) const;
const iterator begin() const;
const iterator end() const;
// capacity:
size type size() const;
size type max size() const;
bool empty() const;
unsigned mark count() const;
string str() const;
```

正则表达式 - 类 regex

- 使用 regex
 - ◆ 包含头文件 <boost/regex.hpp>

```
using boost::regex;
regex e1;
e1 = "^[[:xdigit:]]*$";
cout << e1.str() << endl;</pre>
cout << e1.mark count() << endl; // 1</pre>
regex e2("\b\\w+(?=ing)\b.{2,}?([[:alpha:]]*)$",
        regex::perl regex::icase
        regex::save subexpression location);
cout << e2.str() << endl;</pre>
cout << e2.mark count() << endl; // 2</pre>
// 如果regex e2 未设save subexpression location
// subexpression()将会抛出异常
pair<regex::const iterator, regex::const iterator> sub1 =
        e2.subexpression(1);
string sub1Str(sub1.first, ++sub1.second);
cout << sub1Str << endl;</pre>
```

正则表达式 - 类 match_results



■ 正则表达式:

- 语法
- 类 regex
- 类 match results
- 类 sub_match
- 算法 regex_match()、 regex_search()、 regex_replace()
- 迭代器 regex_iterator 、 regex_token_iterator
- 示例

- 关于 class match_results
 - class match_results 是记录一个正则表达式匹配过程中,每个子表达式的(或整个表达式)的匹配结果,如:
 - 表达式: '\b\w+\b ([0-6]*)' 匹配字符串: 'abcd 12 a_n 005'
 - 整个表达式命中 2 次: 'abcd 12'和 'a n 005'
 - 第 1 个子表达式 '([0-6]*)' 也命中 2 次: '12' 和 '005'
 - match_results 中通过一个或多个 sub_match 对象记录这些命中的字符串的起止位置(而不是真正意义上的字符串内容,只记录代表位置的迭代器)
 - match_results 的内部拥有一个容纳 sub_match 对象的 vector (或其它序列容器)
 - 注意:如果有匹配,则整个表达式匹配的结果作为第一个 sub_match 放在 match_results 中(下标为0)

■ 构造、复制、析构

```
template <class BidirectionalIterator,
class Allocator = std::allocator<sub match<BidirectionalIterator> >
class match results {
public:
    // construct/copy/destroy:
    explicit match results(const Allocator& a = Allocator());
    match results(const match results& m);
    match results& operator=(const match results& m);
    ~match results();
    // size:
    size type size() const;
    size type max size() const;
    bool empty() const;
   // ...
```



■ 一些内部定义的类型:

```
template <class BidirectionalIterator,
class Allocator =
std::allocator<sub_match<BidirectionalIterator> >
class match_results {
public:
    // ...
    typedef sub_match<BidirectionalIterator> value_type;
    typedef const value_type& const_reference;
    typedef const_reference reference;
    // ...
};
```

■ 常用操作

```
// element access:
    difference type length(int sub = 0) const;
    difference type length(const char type* sub) const;
    template <class charT>
    difference type length(const charT* sub) const;
    template <class charT, class Traits, class A>
    difference type length(const std::basic string<charT,
Traits, A>& sub) const;
    difference type position(unsigned int sub = 0) const;
    difference type position(const char type* sub) const;
    template <class charT>
    difference type position(const charT* sub) const;
    template <class charT, class Traits, class A>
    difference type position(const std::basic string<charT,
Traits, A>& sub) const;
```

常用操作(续1)

```
string type str(int sub = 0) const;
    string type str(const char type* sub)const;
    template <class Traits, class A>
    string type str(const std::basic string<char type, Traits,
A>& sub)const;
    template <class charT>
    string type str(const charT* sub)const;
    template <class charT, class Traits, class A>
    string type str(const std::basic string<charT, Traits, A>&
sub) const;
    const reference operator[](int n) const;
    const reference operator[](const char type* n) const;
    template <class Traits, class A>
    const reference operator[](const
std::basic string<char type, Traits, A>& n) const;
    template <class charT>
    const reference operator[](const charT* n) const;
    template <class charT, class Traits, class A>
    const reference operator[](const std::basic string<charT,</pre>
Traits, A>& n) const;
```



常用操作(续2)

```
const reference prefix() const;
const reference suffix() const;
const iterator begin() const;
const iterator end() const;
// format:
template <class OutputIterator, class Formatter>
OutputIterator format(OutputIterator out,
        Formatter fmt,
        match flag type flags = format default) const;
template <class Formatter>
string type format(Formatter fmt,
        match flag type flags = format default) const;
allocator type get allocator() const;
void swap(match results& that);
```

正则表达式 - 类 match_results



typedef of match_results



- 使用 match_results
 - 使用类 match_results 须包含头文件: <boost/regex.hpp>

```
using boost::regex;
regex e1("\\bT\\w+\\b ([[:xdigit:]]+)");
string s("Time ef09, Todo 001");
boost::smatch m;
bool b = boost::regex search(s, m, e1, boost::match all);
cout << b << endl;
const int n = m.size();
for (int i = 0; i < n; ++i) {
    cout << "matched " << i << " position: "</pre>
         << m.position(i) << ", ";</pre>
    cout << "length: " << m.length(i) << ", str: ";</pre>
    cout << m.str(i) << endl;</pre>
}
```

正则表达式 - 类 sub_match



■ 正则表达式:

- 语法
- 类 regex
- 类 match results
- 类 sub_match
- 算法 regex_match()、 regex_search()、 regex_replace()
- 迭代器 regex_iterator 、 regex_token_iterator
- 示例

- 关于 class sub_match
 - 一个 sub_match 就是一个 pair<lter, Iter> 类型,用来保存某个 子表达式匹配结果的起止位置(指向源字符串的迭代器), 如:
 - 表达式 e: '(ab)[df2]' 匹配字符串 s: 'kky<u>abf</u>m'
 - 子表达式 '(ab)' 匹配目标字符串 s 中的 ab, 范围是: s.begin()+3 到 s.begin()+5, 则 sub_match 对象 sm 的 sm.first = s.begin()+3, sub_match.second = s.begin()+5
 - sub_match 一般配合 match_results 使用

class sub_match 接口

```
template<class BIter>
class sub match: public std::pair<BIter, BIter> {
public:
    typedef typename iterator traits<BIter>::value type
value type;
    typedef typename iterator traits<BIter>::difference type
difference type;
    typedef BIter iterator;
   bool matched;
    difference type length() const;
    operator basic string<value type>() const;
    basic string<value type> str() const;
    int compare(const sub match& s) const;
    int compare(const basic string<value type>& s) const;
    int compare(const value type* s) const;
};
```

■ 正则表达式:

- 语法
- 类 regex
- 类 match results
- 类 sub_match
- 算法 regex_match() 、 regex_search() 、 regex_replace()
- 迭代器 regex_iterator 、 regex_token_iterator
- 示例

正则表达式 - 算法函数 regex_match



- 关于 regex_match 函数
 - regex_match 用于一个表达式匹配整个目标字符串的情形,该 函数通常用于输入验证,如:
 - 表达式 e: '([a-d]+)mk' 匹配字符串 s: '#<u>aabmk</u>T'
 - 尽管表达式 e 可以匹配 s 的 aabmk ,但函数 regex_match() 还是返回 false ,因为表达式 e 没有完整 的匹配完 s 整个字符串
 - 如果要查询某个字符串中是否含有指定样式的串,应该使用 regex_search()
 - regex_match() 函数有 6 种形式:
 - 三种类型输入源(一对迭代器指代一个字符序列、 string 类型、 char* 类型)
 - ▶ 上述 3 中形式各有保存匹配结果和不保存匹配结果 2 中形式



■ regex_match 函数接口

```
template<class BIter, class Allocator,
class charT, class traits>
bool regex match(BIter first, BIter last,
       match results& m, // 保存匹配结果
       const regex& e,
       match flag type flags = match default);
template<class BIter, class charT, class traits>
bool regex match (BIter first, BIter last,
       const regex& e,
       match flag type flags = match default);
template<class charT, class Allocator, class traits>
bool regex match(const charT* str,
       match results& m, // 保存匹配结果
        const regex& e,
       match flag type flags = match default);
```



■ regex_match 函数接口(续)

```
template<class charT, class traits>
bool regex match(const charT* str,
        const regex<charT, traits>& e,
       match flag type flags = match default);
template<class ST, class SA, class Allocator,
class charT, class traits>
bool regex match(const string& s,
       match results& m, // 保存匹配结果
        const regex& e,
        match flag type flags = match default);
template < class ST, class SA, class charT, class traits >
bool regex match(const string& s,
        const regex& e,
       match flag type flags = match default);
```



■ regex_match 示例

```
using boost::regex;
regex e("\\w{6,}");

string line;
while (getline(cin, line)) {
   if (line == "quit")
       break;

   if (regex_match(line, e, boost::match_default))
       cout << "Matched" << endl;
   else
      cout << "No Match" << endl;
}</pre>
```

正则表达式 - 算法函数 regex_search



- 关于 regex_search 函数
 - regex_search 的接口同 regex_match 类似,与 regex_match 不同的是, regex_search 在表达式匹配源字符串的部分或全部时返回 true,如:
 - 表达式 e: '([a-d]+)mk' 匹配字符串 s: '#<u>aabmk</u>T'
 - 表达式e可以匹配s的aabmk,所以函数regex_search()返回true
 - regex_search() 函数有 6 种形式:
 - 三种类型输入源(一对迭代器指代一个字符序列、 string 类型、 char* 类型)
 - ▶ 上述 3 中形式各有保存匹配结果和不保存匹配结果 2 中形式



■ regex_search 函数接口

```
template<class BIter, class Allocator,
class charT, class traits>
bool regex search (BIter first, BIter last,
       match results& m, // 保存匹配结果
       const regex& e,
       match flag type flags = match default);
template<class BIter, class charT, class traits>
bool regex search (BIter first, BIter last,
       const regex& e,
       match flag type flags = match default);
template<class charT, class Allocator, class traits>
bool regex search(const charT* str,
       match results& m, // 保存匹配结果
        const regex& e,
       match flag type flags = match default);
```



■ regex_search 函数接口(续)

```
template<class charT, class traits>
bool regex search(const charT* str,
        const regex<charT, traits>& e,
        match flag type flags = match default);
template<class ST, class SA, class Allocator,
class charT, class traits>
bool regex search (const string& s,
        match results& m, // 保存匹配结果
        const regex& e,
        match flag type flags = match default);
template < class ST, class SA, class charT, class traits >
bool regex search(const string& s,
        const regex& e,
        match_flag_type flags = match default);
```



regex_search 示例

```
using boost::regex;
regex e1("\\bT\\w+\\b ([[:xdigit:]]+)");
string s("Time ef09, Todo 001");
boost::smatch m;
bool b = boost::regex search(s, m,
            el, boost::match default);
cout << *(m[1].first) << ' ' << *(m[1].second) << endl;</pre>
cout << "----" << endl:
const int n = m.size();
for (int i = 0; i < n; ++i) {
    cout << "matched " << i << " position: "</pre>
          << m.position(i) << ", ";</pre>
    cout << "length: " << m.length(i) << ", str: ";</pre>
    cout << m.str(i) << endl;</pre>
}
```

正则表达式 - 算法函数 regex_replace



- 关于 regex_replace 函数
 - regex_replace 在匹配的同时作替换动作
 - ◆ 接口:

regex_replace 函数示例

```
using boost::regex;
regex e1("([TQV])|(\\*)|(@)");
string replaceFmt("(\L?1$\&)(?2+)(?3#)");
string src("guTdQhV@@g*b*");
cout << "before replaced: " << src << endl;</pre>
// 注意: format all
string newStr1 = regex replace(src, e1, replaceFmt,
       boost::match default | boost::format all);
cout << "after replaced: " << newStr1 << endl;</pre>
// 注意: format default
string newStr2 = regex replace(src, e1, replaceFmt,
        boost::match default | boost::format default);
cout << "after replaced: " << newStr2 << endl;</pre>
// 另一种形式的调用
ostream iterator<char> oi(cout);
regex_replace(oi, src.begin(), src.end(), e1, replaceFmt,
        boost::match default | boost::format all);
```

■ 正则表达式:

- 语法
- 类 regex
- 类 match_results
- 类 sub_match
- 算法 regex_match()、 regex_search()、 regex_replace()
- 迭代器 regex_iterator 、 regex_token_iterator
- 示例

正则表达式 - 迭代器 regex_iterator



- 关于迭代器 regex_iterator
 - regex_iterator 可以迭代一次匹配过程中匹配的结果,该迭代器 实际上指向的是 match_results 对象



■ 迭代器 regex_iterator 接口

```
template<class BIter, class charT =</pre>
iterator traits < BIter >:: value type,
        class traits = regex traits<charT> >
class regex iterator {
public:
    typedef basic regex<charT, traits> regex type;
    typedef match results < BIter > value type;
    typedef typename iterator traits<BIter>::difference type
difference type;
    typedef const value type* pointer;
    typedef const value type& reference;
    typedef std::forward iterator tag iterator category;
    regex iterator();
    regex iterator(BIter a, BIter b, const regex_type& re,
            match flag type m = match default);
    regex iterator(const regex iterator&);
```



■ 迭代器 regex_iterator 接口(续)

```
regex_iterator& operator=(const regex_iterator&);
bool operator==(const regex_iterator&) const;
bool operator!=(const regex_iterator&) const;
const value_type& operator*() const;
const value_type* operator->() const;
regex_iterator& operator++();
regex_iterator operator++(int);
};
```

```
typedef regex_iterator<const char*> cregex_iterator;
typedef regex_iterator<std::string::const_iterator>
sregex_iterator;

#ifndef BOOST_NO_WREGEX
typedef regex_iterator<const wchar_t*> wcregex_iterator;
typedef regex_iterator<std::wstring::const_iterator>
wsregex_iterator;
#endif
```

正则表达式 - 迭代器 regex_iterator



■ 迭代器 regex_iterator 相关的辅助函数



■ 迭代器 regex_iterator 示例

```
using boost::regex;
regex e("(a+).+?", regex::icase);

string s("ann abb aaat");

boost::sregex_iterator it1(s.begin(), s.end(), e);
boost::sregex_iterator it2; // 结束迭代器

for (;it1 != it2; ++it1) {
    boost::smatch m = *it1;
    cout << m << endl;
}</pre>
```

正则表达式 - 迭代器 regex_token_iterator 种轻IT培训



- 关于迭代器 regex token iterator
 - 模板类 regex token iterator 是迭代器适配器; 它以新的方式 (遍历序列中正则表达式的所有出现,并以一个或多个字符序列 表示每个匹配)表示一个已经存在的迭代器序列。 迭代器遍历 的每个位置都是一个 sub match 对象,表示正则表达式中的特 定子表达式匹配。

当类 regex token iterator 用序号 -1 来遍历单个子表达式时, 迭代器执行区域分割: 也就是说,遍历所有未被表达式匹配的 文本序列。

正则表达式 - 迭代器 regex_token_iterator 种核工术



迭代器 regex token iterator 接口

```
template<class BIter, class charT =</pre>
iterator traits<BIter>::value type,
        class traits = regex traits<charT> >
class regex token iterator {
public:
    typedef basic regex<charT, traits> regex type;
    typedef sub match<BIter> value type;
    // ...
    regex token iterator();
    regex token iterator(BIter a, BIter b, const regex type&
re, int submatch = 0, match flag type m = match default);
    regex token iterator(BIter a, BIter b,
        const regex type& re,
        const std::vector<int>& submatches,
       match flag type m = match default);
```

正则表达式 - 迭代器 regex_token_iterator 种核工术



迭代器 regex token iterator 接口(续)

```
template<std::size t N>
    regex token iterator(BIter a, BIter b,
       const regex type& re, const int(&submatches)[N],
       match flag type m = match default);
    regex token iterator(const regex token iterator&);
    regex token iterator& operator=(const
regex token iterator&);
    bool operator==(const regex token iterator&) const;
    bool operator!=(const regex token iterator&) const;
    const value type& operator*() const;
    const value type* operator->() const;
    regex token iterator& operator++();
    regex token iterator operator++(int);
};
```

正则表达式 - 迭代器 regex_token_iterator 种核 ITV



typedef of regex token iterator

```
typedef regex token iterator<const char*>
cregex token iterator;
typedef regex token iterator<std::string::const iterator>
sregex token iterator;
#ifndef BOOST NO WREGEX
typedef regex token iterator<const wchar t*>
wcregex token iterator;
typedef regex token iterator << std::wstring::const iterator >
wsregex token iterator;
#endif
```

正则表达式 - 迭代器 regex_token_iterator 种核工



■ 迭代器 regex token iterator 辅助函数

```
template <class charT, class traits>
regex token iterator<const charT*, charT, traits>
  make regex token iterator(
         const charT* p,
         const basic regex<charT, traits>& e,
         int submatch = 0,
         regex constants::match flag type m =
regex constants::match default);
template <class charT, class traits, class ST, class SA>
regex token iterator<typename string::const iterator, charT,
traits>
  make regex token iterator(
         const string& p,
         const basic regex<charT, traits>& e,
         int submatch = 0,
         regex constants::match flag type m =
regex constants::match default);
```



迭代器 regex token iterator 辅助函数(续1)

```
template <class charT, class traits, std::size t N>
regex token iterator<const charT*, charT, traits>
make regex token iterator(
         const charT* p,
         const basic regex<charT, traits>& e,
         const int (&submatch)[N],
         regex constants::match flag type m =
regex constants::match default);
template <class charT, class traits,</pre>
          class ST, class SA, std::size t N>
regex token iterator<
      typename string::const iterator, charT, traits>
   make regex token iterator(
         const std::basic string<charT, ST, SA>& p,
         const basic regex<charT, traits>& e,
         const int (&submatch)[N],
         regex constants::match flag type m =
regex constants::match default);
```

正则表达式 - 迭代器 regex_token_iterator 种较工格



迭代器 regex_token_iterator 辅助函数(续2)

```
template <class charT, class traits>
regex token iterator<const charT*, charT, traits>
  make regex token iterator(
         const charT* p,
         const basic regex<charT, traits>& e,
         const std::vector<int>& submatch,
         regex constants::match flag type m =
regex constants::match default);
template <class charT, class traits, class ST, class SA>
regex token iterator<
      typename string::const iterator, charT, traits>
  make regex token iterator(
         const string& p,
         const basic_regex<charT, traits>& e,
         const std::vector<int>& submatch,
         regex constants::match flag type m =
regex constants::match default);
```

正则表达式 - 迭代器 regex_token_iterator 种核工术



迭代器 regex token iterator 示例

```
string s("This is a string of tokens");
    boost::regex re("\\s+");
    boost::sregex token iterator i(s.begin(), s.end(), re,
-1);
    boost::sregex token iterator j;
    unsigned count = 0;
    while (i != j) {
        cout << *i++ << endl:
        count++;
    cout << "There were " << count << " tokens found." <<</pre>
endl;
```

■ 正则表达式:

- 语法
- 类 regex
- 类 match results
- 类 sub_match
- 算法 regex_match()、 regex_search()、 regex_replace()
- 迭代器 regex_iterator 、 regex_token_iterator
- 示例

正则表达式 - 示例



- 示例
 - (DEMO Using Boost Regex Examples)

- boost.regex 正则表达式提供了一个非常简约并且方便的接口 集,所以调用该库的接口十分轻松。
- boost.regex 中对于匹配的字符串的记录,不是将其 copy 并储存,而是利用 sub_match 来保存匹配字符串序列的起止位置(一对迭代器),所以使用的 boost.regex 的开销很小
- 相对于 boost.regex 的简约接口,其所能支持的正则表达式的语法则非常完备和丰富,要充分发挥 boost.regex 这一利器的威力,理解正则表达式的语法是关键,下面是一些资源:
 - Mastering Regular Expressions, 3rd Edition (Book)
 - http://www.regular-expressions.info/examples.html
- boost.xpressive 是另一个优秀的正则表达式库